

Laporan Tugas 2 — Arsitektur Convolutional Neural Network (CNN)

Perbandingan Arsitektur Custom CNN vs Residual CNN (Mini ResNet) pada Dataset CIFAR-10

Anggota 1: Belia Eka Sukma Mentari (230441100110) **Program Studi:** Sistem Informasi

Anggota 2: Annisa Putri (230441100133)

Dataset: CIFAR-10

BAB I — PENDAHULUAN

1.1 Latar Belakang

Convolutional Neural Network (CNN) merupakan salah satu arsitektur deep learning yang banyak digunakan untuk tugas klasifikasi citra karena kemampuannya dalam mengekstraksi fitur spasial secara otomatis melalui operasi konvolusi. Seiring berkembangnya kebutuhan akan model yang lebih dalam dan stabil, muncul arsitektur Residual Network (ResNet) yang memperkenalkan mekanisme residual connection (shortcut connection) untuk mengatasi permasalahan vanishing gradient pada jaringan yang dalam.

Tugas ini bertujuan untuk merancang, melatih, dan membandingkan dua arsitektur CNN yang berbeda, yaitu Custom CNN sederhana (Model A) dan Residual CNN atau Mini ResNet (Model B), pada dataset CIFAR-10. Perbandingan dilakukan berdasarkan nilai akurasi, jumlah parameter, waktu training, serta hasil confusion matrix.


1.2 Tujuan

- Mengimplementasikan arsitektur Custom CNN dan Residual CNN untuk klasifikasi citra.
- Melatih kedua model pada dataset CIFAR-10 menggunakan skema training, validation, dan testing.
- Membandingkan performa kedua model dari sisi akurasi, jumlah parameter, dan waktu komputasi.
- Menganalisis pengaruh residual connection terhadap proses pembelajaran model.

1.3 Dataset

Dataset yang digunakan adalah CIFAR-10, yaitu kumpulan 60.000 citra berwarna (RGB) berukuran 32×32 piksel yang terbagi ke dalam 10 kelas objek. Data latih (training set) dibagi lagi menjadi 80% data training dan 20% data validation, sedangkan data uji (test set) digunakan secara terpisah untuk mengevaluasi kemampuan generalisasi model. Sebelum digunakan, seluruh citra dinormalisasi menggunakan mean dan standar deviasi 0,5 pada setiap kanal warna.

Gambar Dataset CIFAR-10



Gambar 1.1 Contoh citra dari dataset CIFAR-10 beserta label kelasnya

BAB II — ARSITEKTUR MODEL

2.1 Model A — Custom CNN

Model A merupakan CNN sederhana yang dirancang sendiri (custom), terdiri atas tiga blok konvolusi untuk ekstraksi fitur secara bertahap, kemudian dilanjutkan dengan fully connected layer untuk melakukan klasifikasi ke dalam 10 kelas CIFAR-10. Setiap blok konvolusi terdiri atas layer Conv2D, fungsi aktivasi ReLU, dan MaxPooling untuk mereduksi dimensi spasial.

Blok	Layer	Channel (in→out)	Output Spasial
1	Conv2D (k=3, pad=1) + ReLU + MaxPool2D(2)	3 → 32	16×16
2	Conv2D (k=3, pad=1) + ReLU + MaxPool2D(2)	32 → 64	8×8
3	Conv2D (k=3, pad=1) + ReLU + MaxPool2D(2)	64 → 128	4×4
FC	Flatten → Linear(2048,256) + ReLU → Linear(256,10)	—	10 kelas

Tabel 2.1 Ringkasan arsitektur Model A (Custom CNN)

2.2 Model B — Residual CNN (Mini ResNet)

Model B menggunakan pendekatan Residual Network, di mana setiap blok residual (Residual Block) memiliki dua lapis konvolusi utama serta sebuah shortcut connection berupa konvolusi 1×1 yang menyamakan dimensi channel input dengan output. Hasil dari jalur konvolusi utama dijumlahkan dengan hasil shortcut sebelum melewati fungsi aktivasi ReLU. Mekanisme ini memungkinkan gradient mengalir lebih lancar saat proses backpropagation, sehingga training menjadi lebih stabil pada jaringan yang lebih dalam.

Blok	Layer	Channel (in→out)	Output Spasial
Residual 1	Conv2D→ReLU→Conv2D + shortcut(1×1) → ReLU, lalu MaxPool2D(2)	3 → 32	16×16
Residual 2	Conv2D→ReLU→Conv2D + shortcut(1×1) → ReLU, lalu MaxPool2D(2)	32 → 64	8×8
Residual 3	Conv2D→ReLU→Conv2D + shortcut(1×1) → ReLU, lalu MaxPool2D(2)	64 → 128	4×4

FC	Flatten → Linear(2048, 10)	—	10 kelas
----	----------------------------	---	----------

Tabel 2.2 Ringkasan arsitektur Model B (Residual CNN / Mini ResNet)

2.3 Konfigurasi Training

- Jumlah epoch: 20
- Learning rate: 0.001
- Optimizer: Adam
- Loss function: CrossEntropyLoss
- Batch size: 64

BAB III — HASIL EKSPERIMEN DAN PEMBAHASAN

Evaluasi dilakukan menggunakan training loss, validation loss, training/validation accuracy, jumlah parameter, waktu training, serta confusion matrix pada data uji (test set).

3.1 Perbandingan Training dan Validation Loss


Grafik berikut menunjukkan perubahan nilai loss selama proses training dan validasi pada kedua model CNN selama 20 epoch.



Gambar 3.1 Grafik Training dan Validation Loss Model A vs Model B

3.2 Perbandingan Training dan Validation Accuracy

Grafik berikut menunjukkan kemampuan model dalam melakukan klasifikasi selama proses training. Kedua model menunjukkan tren peningkatan akurasi training seiring bertambahnya epoch, dengan akurasi training akhir berada pada kisaran 97%–99%.



Gambar 3.2 Grafik Training dan Validation Accuracy Model A vs Model B

3.3 Evaluasi pada Test Set

Setelah proses training selesai, kedua model diuji menggunakan data test CIFAR-10 (data yang belum pernah dilihat sebelumnya) untuk mengukur kemampuan generalisasi. Hasil pengujian, jumlah parameter, dan waktu training masing-masing model dirangkum pada tabel berikut.


Model	Jumlah Parameter	Test Accuracy	Waktu Training
Model A — Custom CNN	620.362	73,25 %	1.840,61 detik ($\approx$ 30,7 menit)
Model B — Residual CNN	318.058	73,90 %	4.586,32 detik ($\approx$ 76,4 menit)

Tabel 3.1 Perbandingan hasil eksperimen Model A dan Model B


Berdasarkan tabel di atas, Model B (Residual CNN) memiliki jumlah parameter yang jauh lebih sedikit (318.058) dibandingkan Model A (620.362), namun tetap mampu menghasilkan test accuracy yang sedikit lebih tinggi (73,90% berbanding 73,25%). Hal ini menunjukkan bahwa mekanisme residual connection membantu efisiensi ekstraksi fitur, sehingga model dapat mencapai performa yang setara atau lebih baik dengan jumlah parameter yang lebih kecil. Namun demikian, waktu training Model B jauh lebih lama (sekitar 2,5 kali lipat) dibandingkan Model A, yang kemungkinan disebabkan oleh operasi tambahan pada shortcut connection dan proses penjumlahan feature map di setiap blok residual.

3.4 Confusion Matrix

Confusion matrix digunakan untuk melihat distribusi hasil prediksi model terhadap setiap kelas pada dataset CIFAR-10, sehingga dapat diketahui kelas mana saja yang paling sering tertukar (miss-classified).



Gambar 3.3 Confusion Matrix Model A (Custom CNN)



Gambar 3.4 Confusion Matrix Model B (Residual CNN)

Dari kedua confusion matrix, terlihat bahwa kesalahan klasifikasi pada kedua model banyak terjadi pada kelas-kelas yang memiliki kemiripan visual, misalnya antara kelas hewan tertentu (seperti kucing dan anjing) maupun antara kelas kendaraan yang bentuknya serupa. Pola kesalahan ini relatif konsisten pada kedua model, menandakan bahwa kesulitan tersebut lebih dipengaruhi oleh karakteristik dataset CIFAR-10 itu sendiri dibandingkan oleh pilihan arsitektur.

BAB IV — ANALISIS DAN KESIMPULAN

4.1 Analisis Hasil Eksperimen

Berdasarkan hasil eksperimen yang telah dilakukan menggunakan dataset CIFAR-10, kedua model CNN berhasil melakukan proses klasifikasi terhadap 10 kelas objek dengan menggunakan pendekatan arsitektur yang berbeda. Model A menggunakan arsitektur Custom CNN dengan tiga blok convolutional untuk melakukan ekstraksi fitur secara bertahap, sedangkan Model B menggunakan Residual CNN dengan mekanisme residual connection yang memungkinkan informasi dari layer sebelumnya diteruskan melalui shortcut connection.

Perbandingan hasil eksperimen menunjukkan adanya perbedaan performa antara kedua model berdasarkan nilai akurasi, jumlah parameter, dan waktu training. Residual connection membantu proses propagasi gradient sehingga proses optimasi model menjadi lebih stabil, meskipun pada eksperimen ini konsekuensinya adalah waktu training yang lebih lama.

Selain akurasi, jumlah parameter dan waktu training juga menjadi faktor penting dalam menentukan model yang optimal. Model dengan parameter lebih besar (Model A) memiliki kapasitas ekstraksi fitur yang lebih kompleks, tetapi tidak selalu menjamin akurasi yang lebih tinggi, sedangkan model dengan parameter lebih kecil namun arsitektur yang lebih efisien (Model B) dapat mencapai performa yang setara dengan komputasi yang lebih optimal dari sisi jumlah parameter, walaupun membutuhkan waktu training lebih panjang pada eksperimen ini.

4.2 Kesimpulan

Berdasarkan hasil eksperimen, kedua model CNN mampu melakukan klasifikasi pada dataset CIFAR-10 dengan test accuracy yang relatif berdekatan, yaitu 73,25% untuk Model A dan 73,90% untuk Model B. Perbedaan arsitektur memberikan pengaruh terhadap performa model, di mana residual connection pada Model B membantu proses pembelajaran fitur menjadi lebih stabil dengan jumlah parameter yang lebih sedikit.

Pemilihan model terbaik tidak hanya mempertimbangkan akurasi, tetapi juga jumlah parameter dan waktu komputasi yang dibutuhkan. Apabila prioritas utama adalah efisiensi jumlah parameter, Model B (Residual CNN) menjadi pilihan yang lebih baik. Namun, apabila waktu training menjadi pertimbangan utama, Model A (Custom CNN) lebih unggul karena proses training yang jauh lebih cepat.